

시험대비

시험 범위

※ 출제 범위

인증분야	구분	분류	세부 주제
AI Scientist(공통)	AI Foundations	1. 수학 및 통계 기반	가설 검정 (p-value, 유의수준)
			중심극한정리 (CLT)
			선형대수 (PCA, 고유값/고유벡터)
			다중공선성 (VIF, 상관 행렬)
			손실 함수 (MSE, MAE, Cross-Entropy)
		2. 데이터 핸들링	데이터 불균형 (Oversampling, SMOTE)
			결측치 처리 (Imputation)
			데이터 분할 (시계열)
			전처리(토큰나이저, 불용어)
			전처리 (증강, 정규화)
	AI Modeling	1. 핵심 모델링	ML 학습 방식 (지도, 강화)
			ML 알고리즘 (회귀, 앙상블, SVM, 클러스터링)
			정규화 (L1/L2, 드롭아웃)
			활성화 함수 (ReLU, Sigmoid)
			트랜스포머 (어텐션 메커니즘)
			트랜스포머 (핵심 구조)
		2. 모델 학습 및 평가	딥러닝 학습 (역전파, 연쇄 법칙)
			딥러닝 학습 (기울기 문제)
			딥러닝 학습 (옵티마이저)
			모델 검증 (과적합 진단)
			모델 검증 (데이터 누수)
			모델 검증 (평가 지표)
			모델 검증 (교차 검증)
	AI Engineering	1. 모델 최적화 및 서빙	모델 경량화 (주요 기법)
		2. 시스템 및 인프라	분산 처리 (대규모 학습)
		3. 개발 도구 및 환경	형상 관리 (Git 명령어 및 충돌 해결)
			AI 프레임워크 (PyTorch)

이론

제목 없음

— 이번주 시험 예상 범위(통계
·PCA·Optimizer·Transformer·Distillation·Regularization 등) 완벽 커버 버전이다.

AI Scientist (공통) 실전 대비 30문항

(객관식 + 단답 혼합, 각 10점, 정답  표시 및 해설 포함)

[FOUNDATIONS] (기초이론 / 통계 / PCA / 전처리)

문제 1.

다중공선성(Multicollinearity) 문제가 심할 때 가장 적절한 해결책은?

- ① 표준화(Standardization) 수행
- ② PCA로 차원 축소 
- ③ 학습률 감소
- ④ 데이터 크기 확대

 해설: 높은 상관변수는 $VIF \uparrow \rightarrow$ PCA 또는 변수제거로 해결.

문제 2.

가설검정에서 p-value가 0.03이라는 의미로 올바른 것은?

- ① 귀무가설이 참일 확률이 3%이다.
- ② 귀무가설 하에서 관측값 이상이 나올 확률이 3%이다. 
- ③ 대립가설이 참일 확률이다.
- ④ 유의수준을 초과했으므로 기각한다.

 핵심: p-value는 "H₀ 참일 때 이런 데이터가 나올 확률".

문제 3.

PCA에서 고유값(Eigenvalue)이 크다는 것은?

- ① 해당 주성분이 데이터의 분산을 많이 설명한다.
 - ② 잡음이 많다.
 - ③ 변수 개수가 많다.
 - ④ 다중공선성이 크다.
-

문제 4.

공분산(Covariance)과 상관계수(Correlation)의 차이는?

👉 **답:** 공분산은 단위 의존적이고, 상관계수는 표준화되어 -1~1 범위에서 비교 가능.

문제 5.

결측치(Missing Value) 처리 방법 중 데이터 누출(Leakage)을 방지하는 올바른 방식은?

- ① train/test 전체에 Imputer fit 후 transform
 - ② train에만 fit 후 test는 transform
 - ③ test에만 fit
 - ④ 랜덤 대치
-

문제 6.

정규화(Normalization)와 표준화(Standardization)의 차이로 옳은 것은?

- ① Normalization은 평균0 분산1로 맞춘다.
 - ② Standardization은 [0,1] 범위로 조정한다.
 - ③ Normalization은 [0,1] 스케일링, Standardization은 평균0·분산1
 - ④ 둘 다 동일한 의미
-

문제 7.

Oversampling과 SMOTE의 차이로 옳은 것은?

👉 **답:** Oversampling은 단순 복제, SMOTE는 인접 샘플을 기반으로 합성 데이터 생성

문제 8.

OLS 회귀에서 다중공선성 문제가 생기면 어떤 현상이 나타나는가?

- ① 결정계수(R^2)가 감소한다.
- ② 가중치 분산이 커지고 불안정한 추정치가 된다.
- ③ Loss가 0으로 수렴한다.

④ Gradient 폭발

문제 9.

Bias-Variance Trade-off에서 정규화 강도를 높이면 어떤 효과가 있는가?

- ① 편향↑ 분산↓ ☒
 - ② 편향↓ 분산↑
 - ③ 둘 다 감소
 - ④ 둘 다 증가
-

문제 10.

데이터 분포의 첨도(Kurtosis)가 크다는 의미는?

- ① 꼬리가 두껍다. ☒
 - ② 꼬리가 얇다.
 - ③ 대칭성이 높다.
 - ④ 분산이 작다.
-

♥ [MODELING] (딥러닝 / 옵티마이저 / 손실 / 정규화)

문제 11.

Cross-Entropy가 MSE보다 분류 문제에서 적합한 이유는?

- ① 로그우도 형태로 확률적 출력의 경사 해상도가 높기 때문 ☒
 - ② 오차 제곱합을 최소화하기 때문
 - ③ 이상치에 강건하기 때문
 - ④ 회귀 문제 전용이기 때문
-

문제 12.

ReLU 활성화함수의 단점은?

- ① 계산량이 많다.
 - ② 음수 입력 구간에서 Gradient가 0이 되어 Dead Neuron이 생긴다. ☒
 - ③ Saturation 문제가 없다.
 - ④ 출력이 확률로 제한된다.
-

문제 13.

Adam Optimizer가 SGD보다 빠르게 수렴하는 이유는?

👉 **답:** 1차(momentum)와 2차(momentum²) 모멘트를 이용해 적응적 학습률을 적용하기 때문 

문제 14.

Dropout의 주요 목적은?

- ① 학습속도 향상
 - ② 과적합 방지 
 - ③ 손실감소
 - ④ 가중치 초기화
-

문제 15.

Batch Normalization의 효과는?

- ① 입력값의 분산을 줄여 학습을 안정화한다. 
 - ② 학습률을 자동 조정한다.
 - ③ 과적합 방지 전용이다.
 - ④ 출력층 가중치를 감소시킨다.
-

문제 16.

학습률(Learning Rate)이 너무 크면 나타나는 현상은?

- ① 최적점 근처에서 진동하거나 발산 
 - ② 과적합
 - ③ 학습 속도 저하
 - ④ 손실 0 수렴
-

문제 17.

Early Stopping의 주된 목적은?

👉 **답:** 검증 오차가 더 이상 개선되지 않을 때 학습을 중단해 과적합을 방지한다. 

문제 18.

L1 Regularization은 어떤 효과를 낳는가?

- ① 가중치 폭발 방지
- ② 희소성(Sparsity) 유도 

- ③ 학습률 감소
 - ④ Batch 효과 개선
-

문제 19.

Optimizer와 손실함수의 조합 중 일반적으로 가장 안정적인 것은?

- ① MSE + SGD
 - ② CrossEntropy + Adam 
 - ③ MAE + RMSProp
 - ④ CE + SGD
-

문제 20.

Gradient Vanishing 문제가 심할 때 적절한 활성화함수는?

- ① Sigmoid
 - ② ReLU 
 - ③ Softmax
 - ④ Tanh
-

문제 21.

정규화(Regularization)와 Dropout의 공통 목표는?

👉 **답:** 모델 복잡도를 줄여 일반화 성능을 향상시키는 것 

문제 22.

Learning Rate Scheduler의 역할은?

- ① Epoch에 따라 학습률을 점진적으로 조정해 수렴 안정화 
 - ② 가중치 감소
 - ③ Batch 크기 조정
 - ④ Dropout 제어
-

문제 23.

Batch 크기를 너무 크게 하면 생길 수 있는 문제는?

- ① 학습 불안정
- ② 일반화 성능 저하 

- ③ GPU 메모리 감소
- ④ 수렴속도 향상

[ENGINEERING] (PyTorch / Pipeline / Transformer / Distillation)

문제 24.

PyTorch에서 추론 시 반드시 사용하는 구문은?

```
model.eval()
with torch.no_grad():
    y_pred = model(x)
```

이 코드의 의미는?

👉 **단답:** 역전파를 비활성화하여 그래프 생성을 막고 메모리 효율적인 추론 수행 

문제 25.

Scikit-learn Pipeline의 주된 목적은?

- ① 코드 단축
- ② 데이터 전처리와 모델 단계를 묶어 재현성을 보장 
- ③ 속도 향상
- ④ 시각화

문제 26.

Knowledge Distillation에서 Teacher-Student 관계로 옳은 것은?

- ① Teacher는 간단한 모델이다.
- ② Student가 Teacher의 soft label을 학습한다. 
- ③ Student가 Teacher를 fine-tuning한다.
- ④ Teacher는 Student보다 작은 모델이다.

문제 27.

Transformer의 Positional Encoding이 필요한 이유는?

👉 **단답:** Attention 구조는 순서를 인식하지 못하므로 위치 정보를 더해 순서성을 학습시키기 위해서 

문제 28.

Bagging과 Boosting의 차이로 올바른 것은?

- ① Bagging은 병렬 학습, Boosting은 순차적 학습 ☒
- ② 둘 다 병렬
- ③ 둘 다 순차
- ④ Bagging은 약한 학습기 가중

문제 29.

데이터에 Noise를 추가하는 Regularization 기법의 효과는?

- ① 일반화 성능 향상 ☒
- ② 학습속도 저하
- ③ Overfitting 증가
- ④ Loss 불안정

문제 30.

GPU 학습 시 메모리 오류가 날 때 가장 먼저 시도해야 할 방법은?

- ① Batch size를 줄인다. ☒
- ② Epoch를 늘린다.
- ③ Optimizer를 변경한다.
- ④ Dropout을 제거한다.



점검 요약

영역	문제 수	주요 키워드
Foundations	10	PCA, Regression, Multicollinearity, Imputation
Modeling	12	Optimizer, Activation, Regularization, Scheduler
Engineering	8	PyTorch, Pipeline, Distillation, Transformer



AI Scientist (공통) 실전 오답노트 v1

♥ FOUNDATIONS (기초이론 / 통계 / PCA / 전처리)

문제 1.

다중공선성(Multicollinearity) 문제가 심할 때 가장 적절한 해결책은?

- ① 표준화(Standardization) 수행
- ② PCA로 차원 축소
- ③ 학습률 감소
- ④ 데이터 크기 확대

💡 힌트: 상관계수가 높은 변수들은 어떤 조치를 취해야 안정적 회귀가 될까?

문제 2.

가설검정에서 p-value가 0.03이라는 의미로 올바른 것은?

- ① 귀무가설이 참일 확률이 3%이다.
- ② 귀무가설 하에서 관측값 이상이 나올 확률이 3%이다.
- ③ 대립가설이 참일 확률이다.
- ④ 유의수준을 초과했으므로 기각한다.

💡 힌트: p-value는 " H_0 가 참이라고 가정할 때의 관측 확률"이다.

문제 3.

PCA에서 고유값(Eigenvalue)이 크다는 것은?

- ① 잡음이 많다.
- ② 해당 주성분이 데이터의 분산을 많이 설명한다.
- ③ 변수 개수가 많다.
- ④ 다중공선성이 크다.

💡 힌트: 주성분이 설명하는 정보량과 고유값의 관계를 떠올려봐.

문제 4.

공분산(Covariance)과 상관계수(Correlation)의 차이는?

💡 힌트: 단위 의존 여부, 값의 범위 (-1~1)

문제 5.

결측치(Missing Value) 처리 시 데이터 누출을 방지하려면 어떻게 해야 할까?

- ① train/test 전체에 Imputer fit 후 transform
- ② train에만 fit 후 test는 transform
- ③ test에만 fit
- ④ 랜덤 대치

 **힌트:** 모델 검증 시 test 데이터 정보가 train 단계에 들어가면 안 된다.

문제 6.

정규화(Normalization)와 표준화(Standardization)의 차이로 옳은 것은?

- ① Normalization은 평균0 분산1로 맞춘다.
- ② Standardization은 [0,1]로 조정한다.
- ③ Normalization은 [0,1], Standardization은 평균0·분산1
- ④ 둘 다 동일

 **힌트:** MinMaxScaler vs StandardScaler 차이를 떠올려봐.

문제 7.

Oversampling과 SMOTE의 차이는?

 **힌트:** 단순 복제 vs 새로운 샘플 생성

문제 8.

OLS 회귀에서 다중공선성이 심하면 어떤 현상이 생길까?

- ① 결정계수(R^2) 감소
- ② 가중치 불안정
- ③ Loss 0
- ④ Gradient 폭발

 **힌트:** VIF 값이 커지면 계수가 어떻게 변할까?

문제 9.

정규화 강도를 높이면 Bias-Variance 트레이드오프에 어떤 변화가 생길까?

 **힌트:** 규제가 강하면 모델은 단순해지고, 단순하면 편향은...?

문제 10.

데이터의 첨도(Kurtosis)가 크다는 의미는?

☁ *힌트:* 꼬리가 두껍거나 이상치 민감한 분포일수록 첨도가 커진다.

💙 MODELING (딥러닝 / 옵티마이저 / 손실 / 정규화)

문제 11.

Cross-Entropy가 MSE보다 분류 문제에서 적합한 이유는?

☁ *힌트:* 확률적 출력의 로그우도 해석 / 경사 해상도

문제 12.

ReLU 활성화함수의 단점은?

☁ *힌트:* 음수 입력 구간에서 미분값이 0이 되어 발생하는 문제

문제 13.

Adam Optimizer가 SGD보다 빠르게 수렴하는 이유는?

☁ *힌트:* 모멘텀과 적응적 학습률 두 가지를 동시에 사용한다.

문제 14.

Dropout의 주요 목적은?

☁ *힌트:* 뉴런 일부를 무작위로 비활성화 → 공적합 억제

문제 15.

Batch Normalization의 주요 효과는?

☁ *힌트:* 배치 단위로 평균·분산을 정규화하여 내부 공변량 변화 완화

문제 16.

학습률이 너무 크면 어떤 현상이 나타날까?

☁ *힌트:* 손실이 수렴하지 않고 진동하거나 발산할 수 있다.

문제 17.

Early Stopping의 목적은?

☁ *힌트:* Validation Loss 기준으로 학습 중단 시점을 판단

문제 18.

L1 Regularization의 주요 효과는?

☁ **힌트:** 가중치를 0으로 만들어 희소성(Sparsity)을 유도

문제 19.

Optimizer와 손실함수의 일반적 조합으로 가장 많이 쓰이는 것은?

☁ **힌트:** 분류에서는 CE + ? , 회귀에서는 MSE + ?

문제 20.

Gradient Vanishing 문제가 심할 때 적절한 활성화함수는?

☁ **힌트:** 미분값이 1 이상 유지되는 비선형 함수 계열

문제 21.

정규화(Regularization)와 Dropout의 공통 목적은?

☁ **힌트:** 모델 복잡도를 줄여 일반화 성능을 향상

문제 22.

Learning Rate Scheduler의 역할은?

☁ **힌트:** Epoch 진행에 따라 학습률을 조정해 수렴 안정화

문제 23.

Batch 크기를 너무 크게 하면 어떤 문제가 생길 수 있을까?

☁ **힌트:** 미세한 잡음이 줄면 일반화가 오히려 나빠질 수 있다.

🧩 ENGINEERING (PyTorch / Pipeline / Transformer / Distillation)

문제 24.

PyTorch 추론 시 `model.eval()` 과 `torch.no_grad()` 를 사용하는 이유는?

☁ **힌트:** 그래프 생성 비활성화 + 메모리 절약

문제 25.

Scikit-learn Pipeline의 주요 목적은?

☁ **힌트:** 전처리-모델 일괄 실행, 재현성 확보

문제 26.

Knowledge Distillation에서 Teacher-Student 관계로 올바른 설명은?

☁ **힌트:** Teacher의 soft label을 Student가 학습

문제 27.

Transformer의 Positional Encoding이 필요한 이유는?

☁ *힌트:* Attention은 순서 정보가 없기 때문

문제 28.

Bagging과 Boosting의 차이를 설명하시오.

☁ *힌트:* 병렬 vs 순차 / 샘플링 방식 차이

문제 29.

데이터에 Noise를 추가하는 Regularization 기법의 주된 효과는?

☁ *힌트:* 학습 데이터 다양화로 일반화 향상

문제 30.

GPU 학습 중 OOM(Out of Memory) 오류가 날 때 가장 먼저 시도할 조치는?

☁ *힌트:* GPU 메모리 점유량을 줄이는 방법 중 가장 단순한 것
